Технології графічного процесінгу

Лекція 1: Вступ

Кочура Юрій Петрович
iuriy.kochura@gmail.com
@y_kochura

Сьогодні

- Будова CPU та GPU
- Переваги використання GPUs
- Паралельний vs Розподілений
- Основні закони паралельних обчислень
- Області застосування гетерогенних паралельних обчислень

Сьогоднішні виклики обчислень

- Навички виконання обчислень є важливими для вивчення практично усіх дисциплін
- Наука про дані та машинне навчання стають основними навичками в більшості STEM
- Практично всі процесори багатоядерні, від мікроконтролерів до суперкомп'ютери
- Промисловість і наукові відкриття вимагають ШІ та прискорених обчислень

Переваги використання **GPUs**

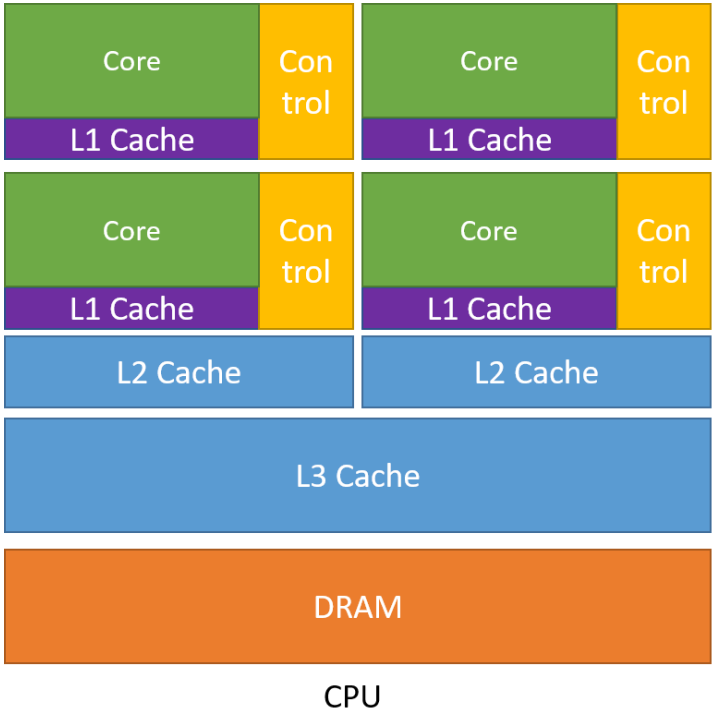

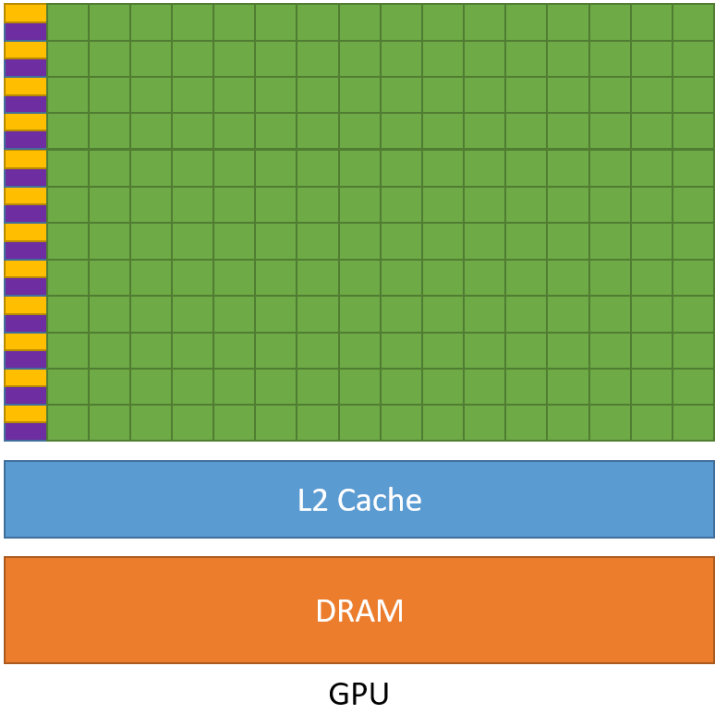

Central Processing Unit (CPU)

Graphics Processing Unit (GPU)

—

Джерело слайду: CUDA C++ Programming Guide, NVIDIA

CPU та **GPU** спроектовані дуже по-різному

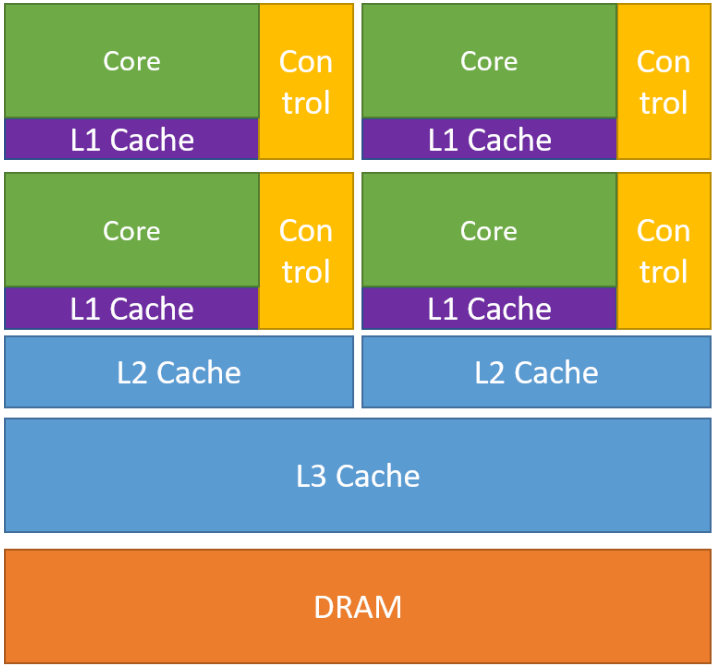

CPU

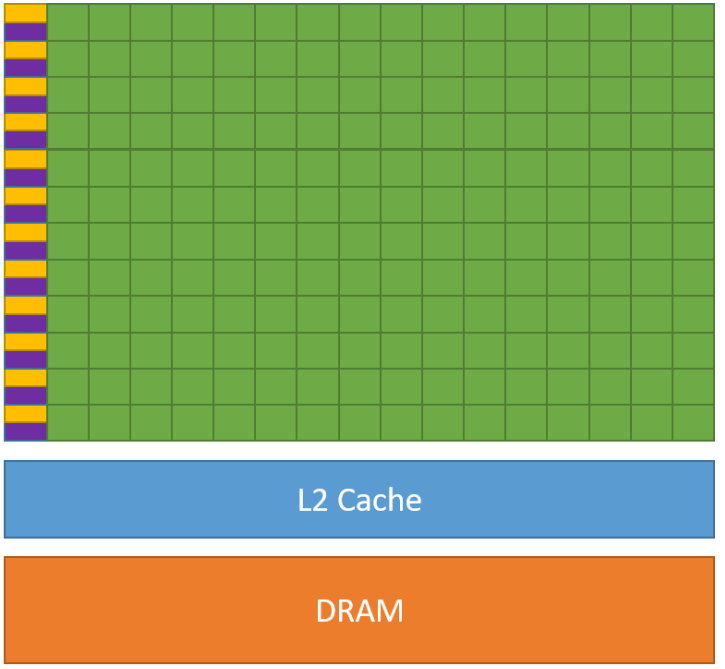

GPU

Ядра орієнтовані на зменшення затримок Latency Oriented Cores

Ядра орієнтовані на збільшення пропускної здатності Throughput Oriented Cores

—

Джерело слайду: CUDA C++ Programming Guide, NVIDIA

CPU: Архітектура орієнтована на зменшення затримок

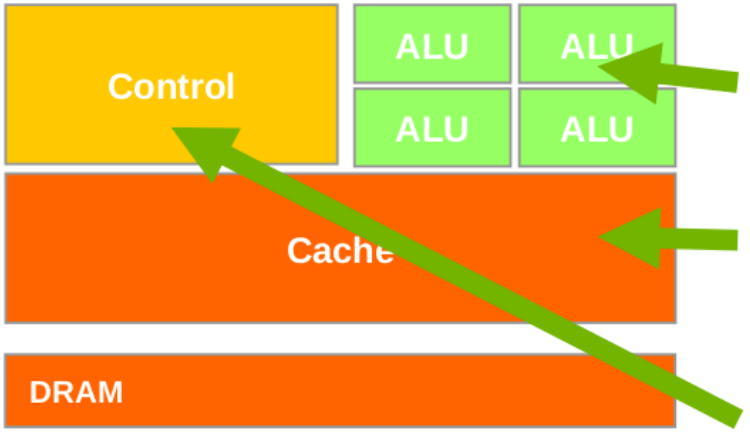

Потужні ALU - Arithmetic Logic Unit

- Зменшення затримок між операціями

Великий розмір кеш пам’яті

- Перетворення доступу від пам'яті з великою затримкою до кешу з короткою затримкою

Складний пристрій керування

- Прогнозування розгалужень для зменшення затримок
- Пересилання даних для зменшення затримок

GPU: Архітектура орієнтована на збільшення пропускної здатності

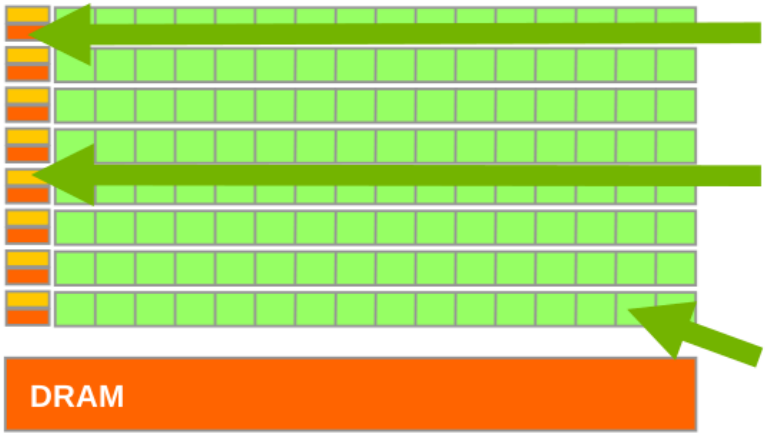

Малий розмір кеш пам’яті

- Для збільшення пропускної здатності пам'яті

Простий пристрій керування

- Відсутнє прогнозування розгалужень
- Відсутнє пересилання даних

Енергоефективні ALUs

- Велика кількість ALU, які мають тривалі затримки, але дозволяють забезпечити високу пропускну здатність. Для цього потрібно задіяти велику кількість потоків, щоб отримати виграш

CPU vs GPU

Джерело: 12th Gen Intel Core

- 12th Gen Intel Core
  - 14 Processor Cores
  - 10 nm process

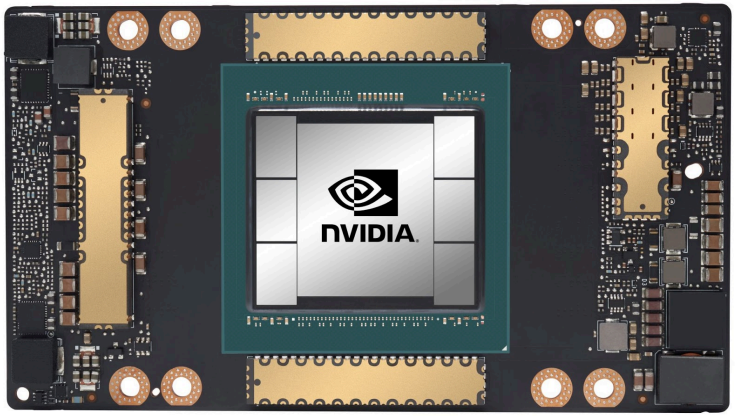

Джерело: NVIDIA Ampere Architecture In-Depth

- NVIDIA A100
  - 6912 CUDA Cores
  - 7 nm process

Програми-переможці використовують як **CPU** так і **GPU**

CPU використовують для послідовних частин коду, де затримки мають значення

CPU може бути в $\times 10$+ швидшим ніж GPU для частин програми, які виконуються послідовно

GPU використовують для паралельних частин коду, де пропускна здатність виграє

GPU може бути в $\times 10$+ швидшим ніж CPU для частин програми, які можуть бути виконані паралельно

Паралельний **vs** Розподілений

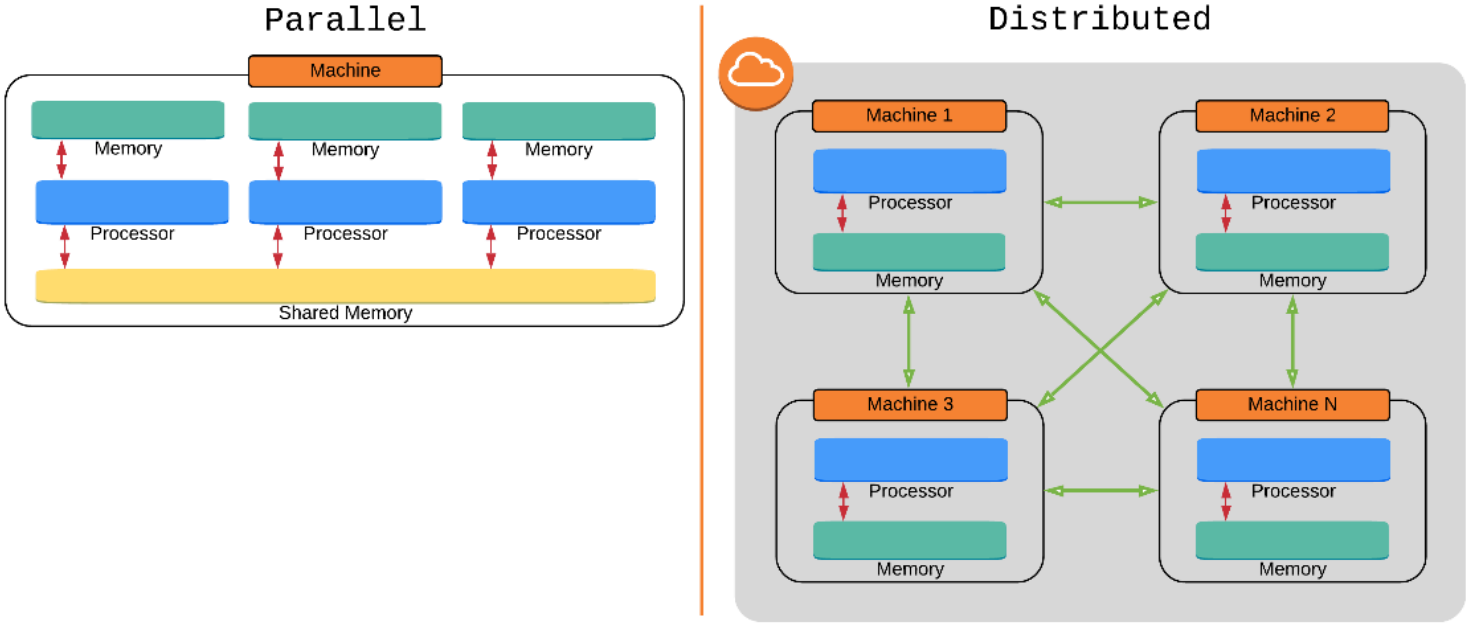

Паралельні обчислення — обчислення, які виконуються одночасно на кількох процесорах в одній системі — багатопотоковій.

Розподілені обчислення — використання кількох процесорів на кількох машинах, які спілкуються через мережу.

—

Джерело слайду: Advanced Algorithms and Data Structures (2021), Marcello La Rocca

Чому паралельні обчислення важливі?

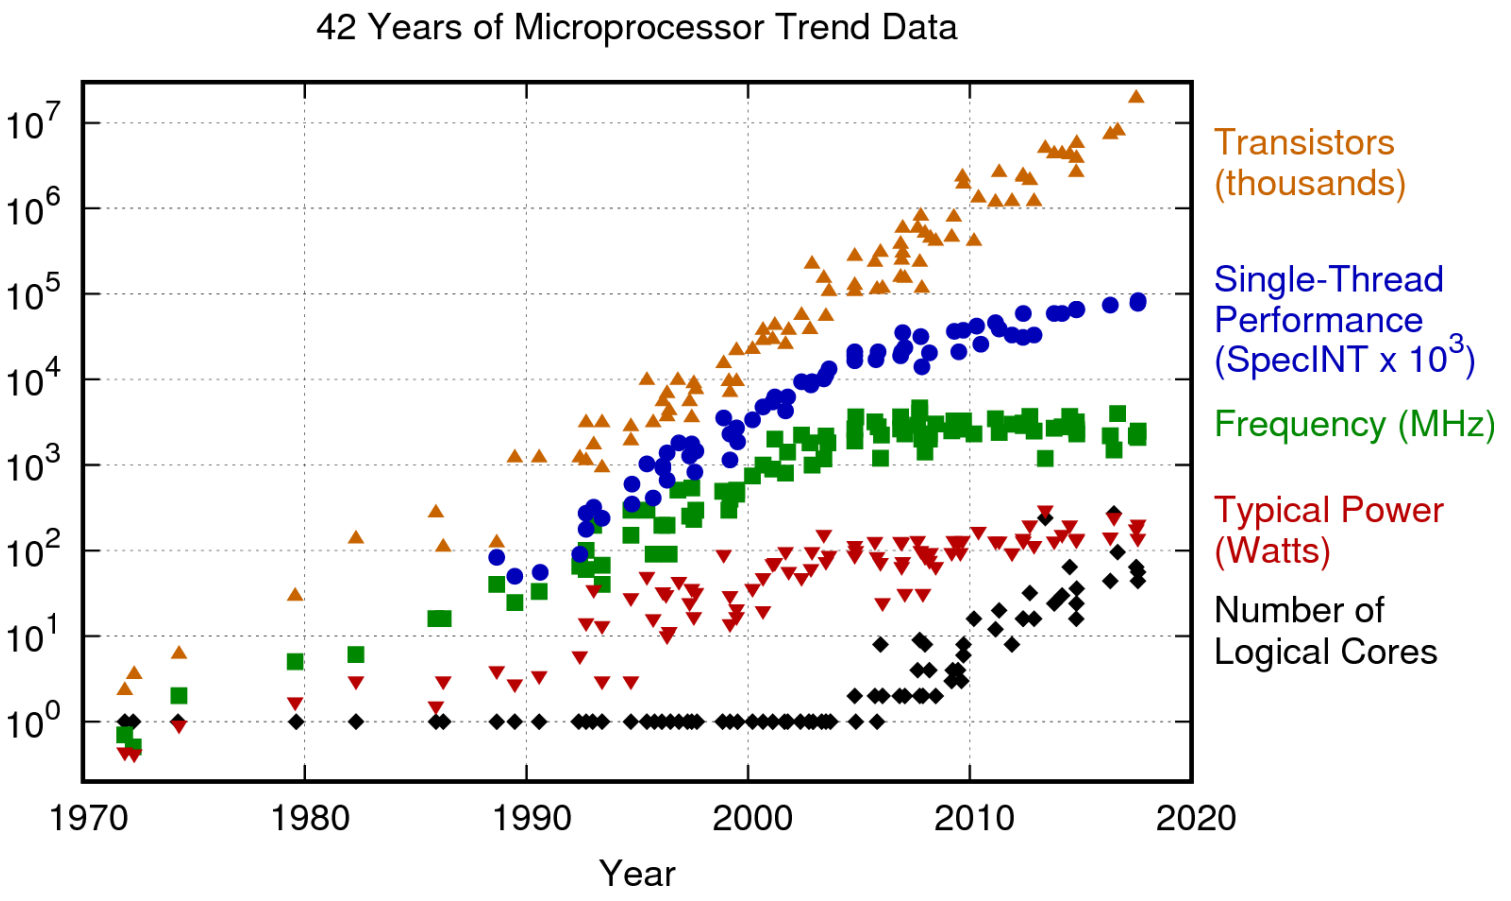

Original data up to the year 2010 collected and plotted by M. Horowitz, F. Labonte, O. Shacham, K. Olukotun, L. Hammond, and C. Batten
New plot and data collected for 2010-2017 by K. Rupp

—

Джерело слайду: 42 Years of Microprocessor Trend Data, Karl Rupp

Example

Let's take a 16-core CPU with hyperthreading and a 256 bit-wide vector unit, commonly found in home desktops. A serial program using a single core and no vectorization only uses 0.8% of the theoretical processing capability of this processor! The calculation is

$$16 \text{ cores} \times 2 \text{ hyperthreads} \times (256 \text{ bit-wide vector unit})/(64\text{-bit double}) = 128\text{-way parallelism}$$

where 1 serial path/128 parallel paths = .008 or 0.8%. The following figure shows that this is a small fraction of the total CPU processing power.

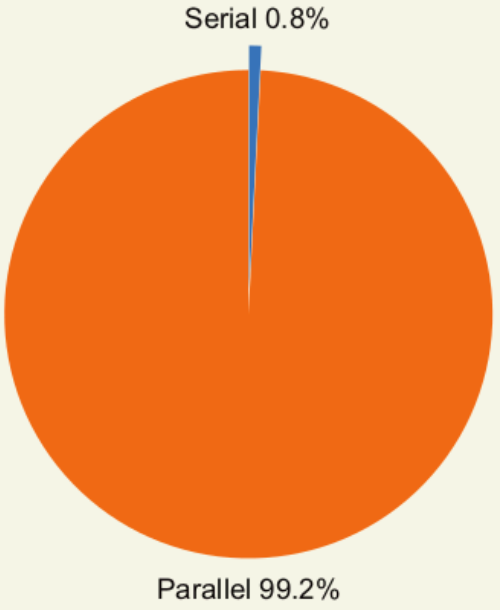

A serial application only accesses 0.8% of the processing power of a 16-core CPU.

—

Джерело слайду: Parallel and High Performance Computing, Robert Robey and Yuliana Zamora

Які потенційні переваги паралельних обчислень?

- Прискорення часу виконання програм
- Підвищення енергоефективності
- Вирішення великих проблем

—

Джерело слайду: Parallel and High Performance Computing, Robert Robey and Yuliana Zamora

Основні закони паралельних обчислень

Межа для паралельних обчислень: закон Амдала

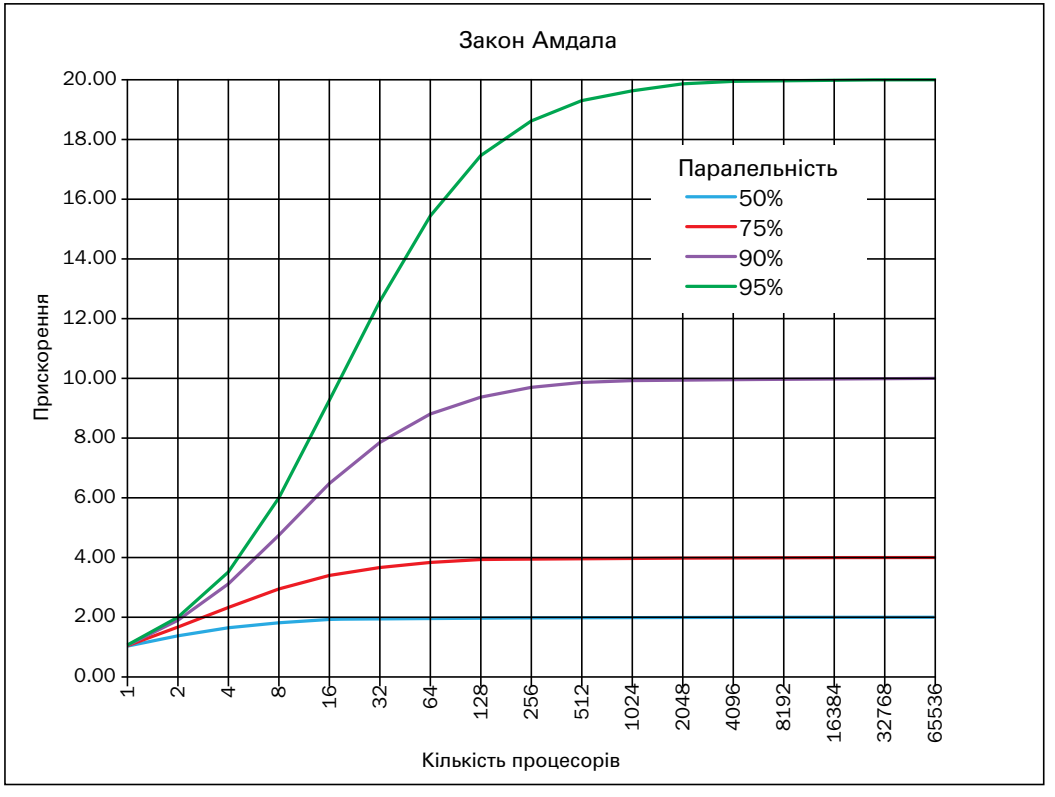

$$\mathrm{SpeedUp}(N) = \frac{1}{S + \frac{P}{N}},$$

де N — кількість процесорів, S — частина яку можна виконувати послідовно, P — частина яку можна виконувати паралельно, $S + P = 1$

—

Джерело слайду: Закон Амдала, Вікіпедія

Прорив паралельної межі: закон Густафсона-Барсіса

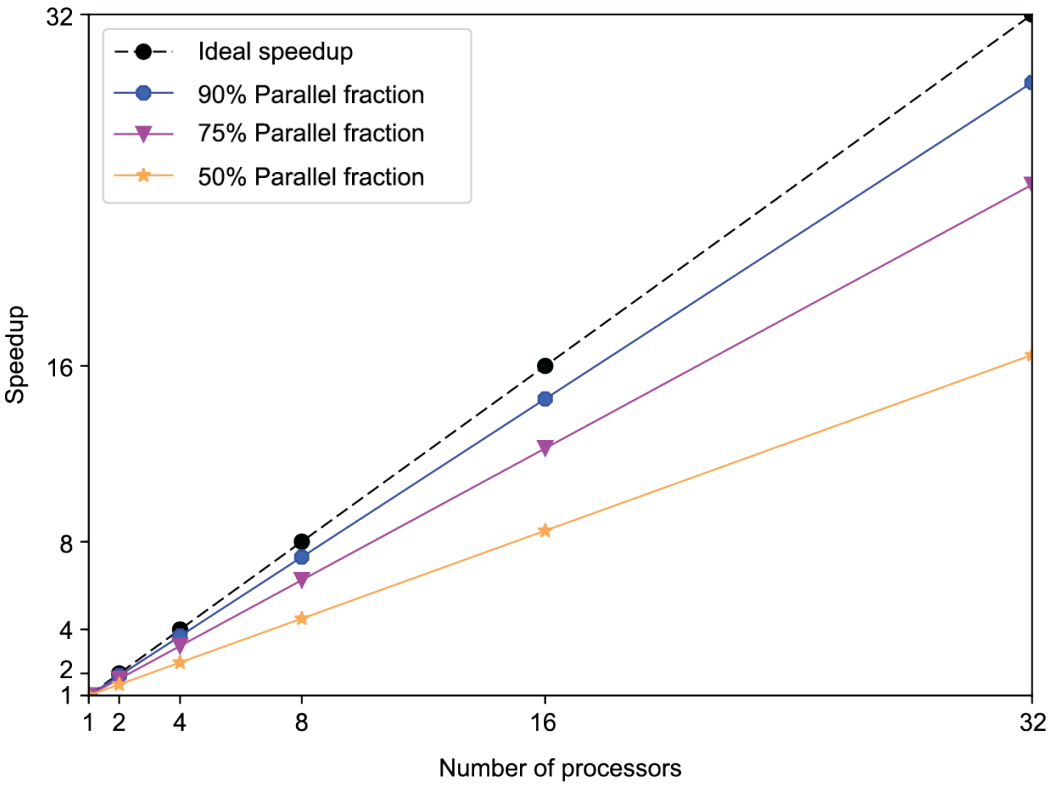

$$\text{SpeedUp}(N) = N - S \cdot (N - 1),$$

де N — кількість процесорів, S — частина яку можна виконувати послідовно

—

Джерело слайду: Parallel and High Performance Computing, Robert Robey and Yuliana Zamora

Застосування

Застосування гетерогенних паралельних обчислень

- Машинне навчання
- Наукове моделювання
- Біомедична інформатика
- Обробка відео
- Фінансова аналітика
- Інженерне моделювання
- Медична візуалізація
- Астрономія та астрофізика

—

Джерело слайду: GPU Applications Catalog, NVIDIA

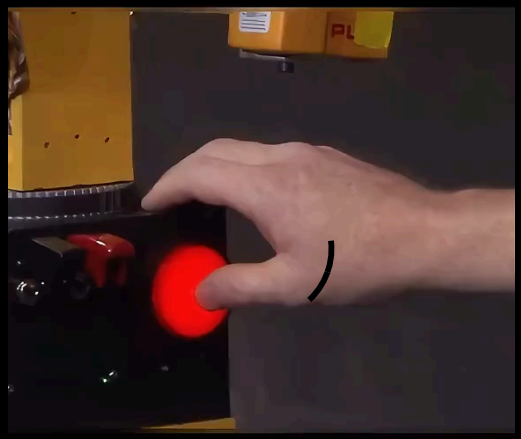

0:00

Демо-версія «Руйнівників міфів»: графічний процесор проти центрального процесора